

Кластеризация и понижение размерности

Clustering & dimensionality reduction

Цель

группировать объекты схожей природы по группам (кластерам) так, чтобы объекты в каждом кластере обладали схожими свойствами, т.е. находились близко друг к другу в каком-либо пространстве

На входе:

- признаковое описание объектов X
- матрица расстояний между объектами

Алгоритм

1. **Инициализация центроидов:** Инициализируем центроиды кластеров случайным образом или выбираем из наблюдений.
 2. **Назначение кластеров:** Для каждой точки данных определяем ближайший кластер по расстоянию до центроидов.
 3. **Перемещение центроидов:** Пересчитываем центроиды кластеров, используя средние значения точек данных в каждом кластере.
 4. **Повторение шагов 2 и 3:** Повторяем назначение кластеров и перемещение центроидов до сходимости алгоритма.
- Смотрим демо: [визуализация Kmeans](#)

Делят выборку не на фиксированное число кластеров, а строят вложенные (иерархические) разбиения.


Алгоритм при *агломеративном* подходе:

1. Каждый объект считаем отдельным кластером
2. Для каждого объекта находим ближайший, объединяем в новые кластеры
3. Повторяем до тех пор, пока не останется один кластер, содержащий все объекты выборки


Дивизимный подход противоположен: сначала все объекты находятся в одном кластере, далее кластер дробится до тех пор, пока число кластеров не станет равно объему выборки.

Agglomerative vs. Divisive


Agglomerative Hierarchical Clustering



Divisive Hierarchical Clustering




Дендрограмма




Если объекты расположены близко друг другу и имеют определенное число соседей, то они принадлежат к одному кластеру

- `sklearn.cluster.DBSCAN`
 - Density-Based Spatial Clustering of Applications with Noise
- `sNN`
 - Shared Nearest Neighbor



DBSCAN






- Внешние / External – меры качества, использующие известное распределение по классам
- Внутренние / Internal – меры качества, оценивающие только признаковую информацию об объектах

Внешние метрики кластеризации



	1	2	3	4	5	6	7	8
1	TP	TP	TP	FP	TN	TN	TN	TN
2	TP	TP	TP	FP	TN	TN	TN	TN
3	TP	TP	TP	FP	TN	TN	TN	TN
4	FP	FP	FP	TP	FN	FN	TN	TN
5	TN	TN	TN	FN	TP	TP	TN	TN
6	TN	TN	TN	FN	TP	TP	TN	TN
7	TN	TN	TN	TN	TN	TN	TP	TP
8	TN	TN	TN	TN	TN	TN	TP	TP

матрица отношений



- **TP**: кластер и класс совпали
- **FP**: один кластер, но разные классы
- **FN**: разные кластеры, но один класс
- **TN**: разные кластеры и разные классы

$$Rand = \frac{TP + TN}{TP + TN + FP + FN}$$

$$0 \leq Rand \leq 1$$

Как называется эта метрика в задачах классификации?

Ext homogeneity(гомогенность)

$$\text{homogeneity} = \frac{TP}{TP + FP}$$

$$0 \leq \text{homogeneity} \leq 1$$

- Что подсвечивает данная метрика, зная, что такое FP
- Как называется эта метрика в задачах классификации?

$$completeness = \frac{TP}{TP + FN}$$

$$0 \leq completeness \leq 1$$

- Что подсвечивает данная метрика, зная, что такое FN
- Как называется эта метрика в задачах классификации?


$$v = \frac{(1 + \beta) \times \text{homogeneity} \times \text{completeness}}{(\beta \times \text{homogeneity} + \text{completeness})}$$

- *homogeneity*: каждый кластер содержит элементы только одного класса
- *completeness*: все элементы одного класса были кластеризованы в один кластер


$$s = \frac{b - a}{\max(a, b)}$$

- a – среднее расстояние между фиксированным объектом и остальными объектами в данном кластере
- b – среднее расстояние между фиксированным объектом и объектами другого кластера





Elbow method



TSNE



UMAP



1. Кластеризация табличных данных
2. Кластеризация текстов
3. Кластеризация изображений (см. пример в [github](#))
4. Квантизация изображений (см. пример в [github](#))

- Кластеризация - способ изучить структуру данных
- В общем виде пайплайн может быть таким
 - i. Загрузка данных
 - ii. Понижение размерности
 - iii. Кластеризация (несколькими разнородными методами)
 - iv. Подсчет метрик, интерпретация и визуализация